

Predição da Estabilidade de uma Smart Grid

Victor Jorge
João Vinicius

4 de setembro de 2024

Sumário

- 1 Smart Grid
- 2 Motivação do Estudo
- 3 Metodologia
- 4 Resultados e Discussões
- 5 Referências

O que é Smart Grid?

- Rede elétrica inteligente que utiliza tecnologia digital.
- Monitora, controla e otimiza produção, distribuição e consumo de energia.
- Integra sistemas de comunicação, automação e dados.
- Permite gestão eficiente da energia e detecção de falhas.
- Facilita a incorporação de fontes de energia renovável.
- Incentiva a participação ativa dos consumidores.

Motivação do Estudo

- Problemas identificados no gerenciamento de redes elétricas
- Necessidade de prever a estabilidade em cenários complexos
- Impacto esperado: Melhorar a confiabilidade e eficiência energética

Metodologia - Visão Geral

- Abordagem de Regressão: Comparação de 18 modelos
- Uso de Algoritmo Genético para otimização de parâmetros
- Avaliação e escolha dos melhores modelos

Regressão - Tipos de Regressão

- Bayesian Ridge Regression
- Automatic Relevance Determination (ARD) Regression
- Lasso Regression
- Ridge Regression
- Linear Regression
- Support Vector Regression (SVR)
- Nu Support Vector Regression (NuSVR)
- Light Gradient Boosting Machine (LGBM)
- k-Nearest Neighbors Regression (KNN)
- Elastic Net Regression
- AdaBoost Regression
- Stochastic Gradient Descent Regression (SGD)
- Extra Trees Regression
- eXtreme Gradient Boosting (XGBoost)
- Multi-layer Perceptron Regression (MLP)
- Random Forest Regression
- Histogram-based Gradient Boosting Regression
- Gradient Boosting Regression

Regressão - Nu Support Vector Regression (NuSVR)

- Utiliza o parâmetro Nu como limite superior e inferior
- Capacidade de modelar relações complexas em dados de alta dimensionalidade
- Resultado: Melhor desempenho em termos de R^2 e MAPE

Regressão - LightGBM

- Combina vários modelos individuais de árvores de decisão para regressão
- Foco em desempenho e rapidez de treinamento
- Resultado: Alta robustez e generalização, com menor tendência ao overfitting

Regressão - Histogram-based Gradient Boosting Regression

Predição da Estabilidade de uma Smart Grid

Victor Jorge
João Vinicius

Smart Grid

Motivação do Estudo

Metodologia

Resultados e Discussões

Referências

- Similar ao LightGBM, mas usa histogramas para simplificar splits
- Melhora a eficiência em grandes conjuntos de dados
- Resultado: Boa precisão, mas tendência ao overfitting em alguns casos

Algoritmo Genético

- Estrutura da equação utilizada:

$$\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_n x_n = Y$$

- Parâmetros: Número de gerações, mutação, crossover, etc.
- Uso da biblioteca pygad para implementação
- Desempenho: Melhorias significativas em parâmetros de regressão

Regressão: Mapa de Calor - Correlações




Figura: Mapa de calor - Correlações

Resultados: MAE dos 18 Modelos

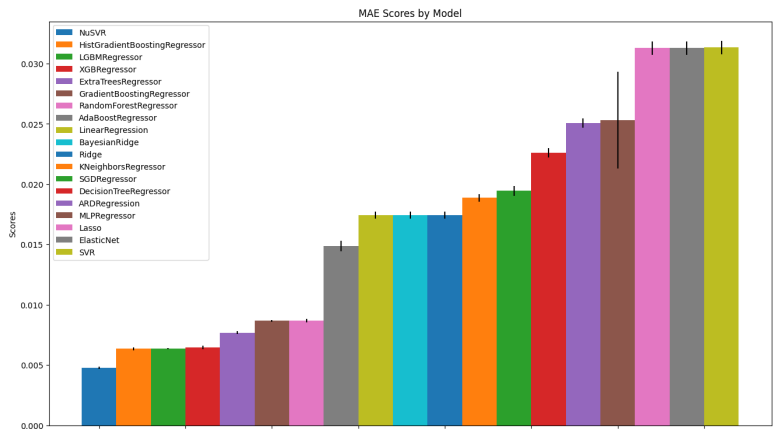


Figura: Resultado MAE dos 18 modelos

Resultados: MSE dos 18 Modelos

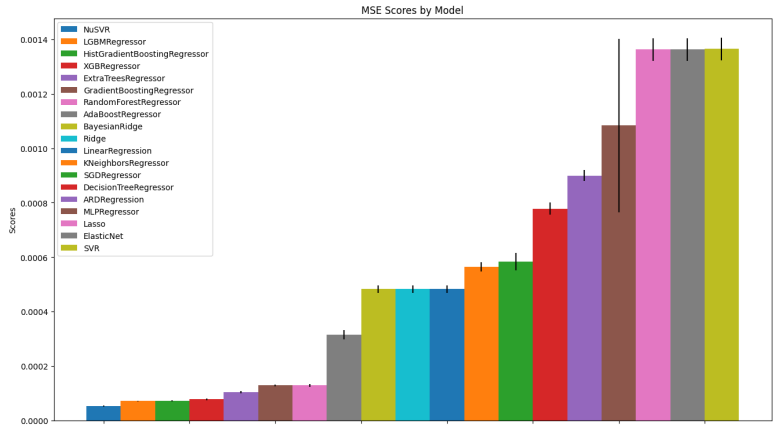


Figura: Resultado MSE dos 18 modelos

Resultados: MAPE dos 18 Modelos




Figura: Resultado MAPE dos 18 modelos

Resultados: R² dos 18 Modelos

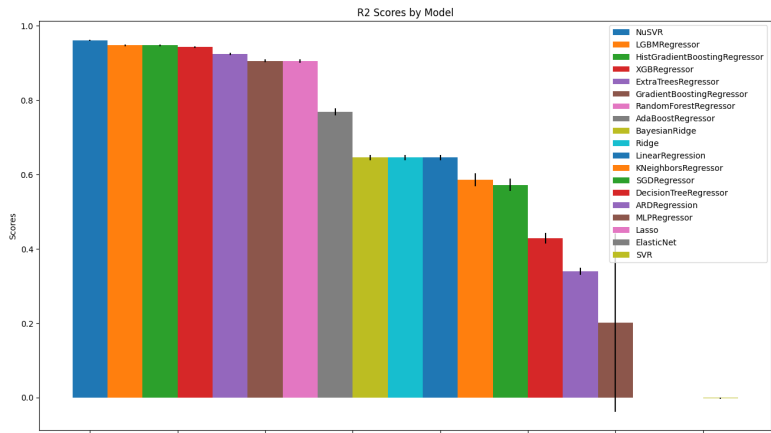


Figura: Resultado R² dos 18 modelos

Modelos Performáticos

Modelos que performaram melhor:

- NuSVR
- LightGBM
- HistGradientBoosting

Análise:

- Aplicado Grid Search para melhorar hiperparâmetros.
- Foram analisados MSE, MAPE, MAE e R^2 .

MSE dos Modelos Escolhidos

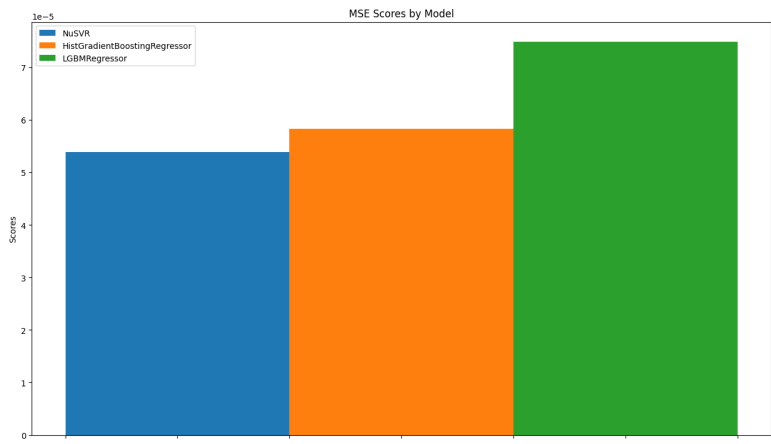


Figura: MSE dos Modelos Escolhidos

MAPE dos Modelos Escolhidos




Figura: MAPE dos Modelos Escolhidos

MAE dos Modelos Escolhidos

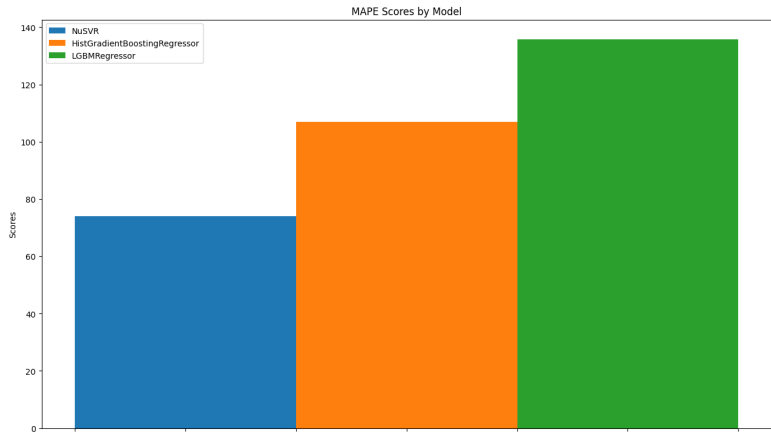


Figura: MAE dos Modelos Escolhidos

R² dos Modelos Escolhidos

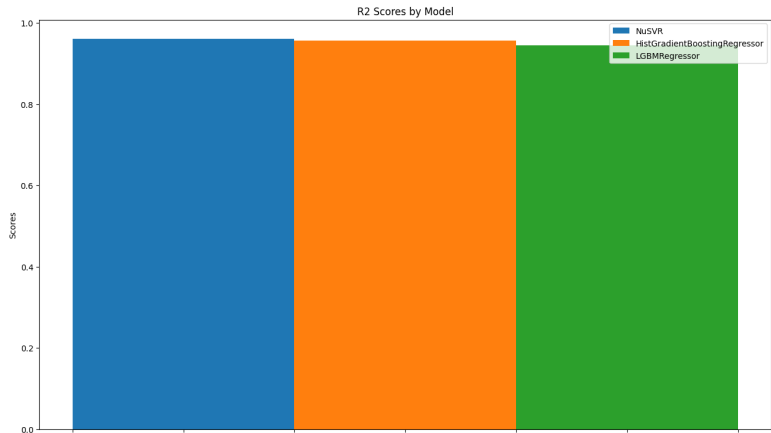


Figura: R² dos Modelos Escolhidos

Função da NuSVR

Comparação de Previsões de Modelos




Figura: Função da NuSVR

Função da HistGradientBoostingRegressor

Comparação de Previsões de Modelos




Figura: Função da HistGradientBoostingRegressor

Discussões sobre Modelos

NuSVR:

- Maior performance, mas com risco de overfitting ao usar 90% dos dados como Vetores de Suporte.

LightGBMRegressor:

- Menor risco de overfitting, melhor capacidade de generalização.

HistGradientBoostingRegressor:

- Tendência ao sobreajuste, mas com ajustes pode se tornar robusto.

Algoritmo Genético: Multivariável




Figura: Gráfico de fitness para AG multivariáveis

Algoritmo Genético: Multivariável - Medidas de Erro

```
Parâmetros da melhor solução : [ 0.00544444  0.00762837 -0.00338671 -0.00723045  1.06432844  1.04125936  
1.07686626  1.06375533 -0.02777068 -0.01248444  0.0059718  0.03094851]  
Fitness da melhor solução = 0.0029829439204406482  
Index da melhor solução : 0  
Mean Absolute Error (MAE) = 0.04279471565650077  
Mean Squared Error (MSE) = 0.0028593838969391532  
Root Mean Squared Error (RMSE) = 0.05347320728120909  
Mean Absolute Percentage Error (MAPE) = 636.6959892684666
```

Figura: Valores de erro do AG de multivariáveis

Análise:

- Medidas de erro e valores dos parâmetros utilizados.

Algoritmo Genético: 80/20




Figura: Gráfico de fitness para AG 80/20

Algoritmo Genético: 80/20 - Medidas de Erro

- **Parâmetros da melhor solução:** [7.93205155e-03, 4.17784195e-04, 6.45921026e-03, 1.92005246e-02, -1.96338026e+00, -1.92890651e+00, -1.99986665e+00, -1.93018442e+00, 7.56142420e-02, 6.09533678e-02, -1.87506567e-01, -1.03931572e-01]
- **Fitness da melhor solução:** 0.001500759904008849
- **Index da melhor solução:** 0
- **MAE:** 0.08038562847020014
- **MSE:** 0.010006329160295811
- **RMSE:** 0.10003164079577927
- **MAPE:** 1064.996180354192

Conclusão sobre Regressão - Parte

1

NuSVR:

- Apresenta bom desempenho, mas é propenso a sobreajuste, comprometendo a generalização.

HistGradientBoostingRegressor:

- Mostra sinais de sobreajuste, necessitando de ajustes para melhorar sua robustez.

Conclusão sobre Regressão - Parte

2

LightGBMRegressor:

- Demonstrou maior resistência ao sobreajuste, sendo uma opção mais confiável para ambientes de dados variados.
- MAPE elevado em ambos os métodos, com melhores resultados para o AG multivariável.

Conclusões sobre Algoritmo Genético

- AG multivariável apresentou melhor desempenho, mas com maior custo computacional.
- Aumentar a quantidade de soluções por população melhora o fitness, mas exige mais recursos.
- O AG simples rodou para mais equações, mas apresentou desempenho geral pior.

Conclusões Finais

- Modelo de Escolha: LightGBMRegressor.
- Parâmetros: $max_depth = 10$
- Medidas de Erro:
 - **MAE:** 0.0063
 - **MSE:** 69.36×10^{-6}
 - **MAPE:** 313.0708
 - **R²:** 0.9494

Referências



V. Arzamasov, K. Böhm, and P. Jochem, "Towards Concise Models of Grid Stability," in *2018 IEEE International Conference on Communications, Control, and Computing Technologies for Smart Grids (SmartGridComm)*, Aalborg, Denmark, 2018, pp. 1-6, doi: 10.1109/SmartGridComm.2018.8587498.



SAP Insights, "The Smart Grid: How AI is Powering Today's Energy Technologies," Available: *SAP Insights*, Accessed: Jul. 11, 2024.



Md. Satu and Md. Imran Khan, "Machine Learning Approaches To Predict The Stability of Smart Grid," 2024, doi: 10.21203/rs.3.rs-3866218/v1.



Y. Shi, G. Ke, D. Soukhavong, J. Lamb, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T. Liu, N. Titov, and D. Cortes, "lightgbm: Light Gradient Boosting Machine," R package version 4.5.0.99, 2024. Available: <https://github.com/Microsoft/LightGBM>.



T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 785-794, doi: 10.1145/2939672.2939785.